

Univerzitet u Beogradu
Matematički fakultet

Predmet: Istraživanje
podataka 2

Klasifikacija mutanata p53 proteina

Seminarski rad iz predmeta Istraživanje podataka 2

Uroš Kovačević 76/2021

Matematički fakultet, Univerzitet u Beogradu
29. jun 2026.

Sadržaj

1	Uvod	2
1.1	Tekst zadatka	2
1.2	Cilj	2
2	Opis podataka	2
3	Preprocesiranje	3
4	Redukcija atributa	4
5	Vizuelizacija podataka	4
6	Metode klasifikacije	5
7	Eksperimentalni rezultati	5
7.1	Rezultati na jednoj podeli	5
7.2	Unakrsna validacija	6
7.3	Podešavanje hiperparametara	6
7.4	Finalni model	7
8	Diskusija	7
9	Zaključak	8

1 Uvod

1.1 Tekst zadatka

Zadatak seminarskog rada je obrada zadatog skupa podataka metodom klasifikacije. Potrebno je izvršiti preprocesiranje podataka, obraditi ih sa najmanje pet algoritama klasifikacije, vizuelno prikazati podatke u 2D ili 3D, napraviti modele sa svim atributima i sa različitim redukovanim skupovima atributa, i uporediti dobijene rezultate. U ovom radu obrađen je skup „p53 Mutants” sa UCI repozitorijuma.

1.2 Cilj

Cilj je predvideti transkripcionu aktivnost mutanata p53 proteina, odnosno svrstati svaki mutant u jednu od dve klase: **active** (transkripciono kompetentan, aktivan p53) ili **inactive** (kancerozni, neaktivni p53). Atributi su biofizičke osobine dobijene simulacijama, a oznake klasa su određene eksperimentalno. Problem je značajan jer prepoznavanje aktivnih mutanata pomaže u istraživanju mehanizama putem kojih se funkcija proteina p53 može povratiti u kancerima.


2 Opis podataka

Skup „p53 Mutants” (verzija K8 iz 2010. godine) sadrži 16772 sloga i 5409 kolona. Prvih 5408 kolona su numerički atributi, a poslednja kolona je ciljna klasa. Atributi se dele na dve grupe: atributi 1–4826 predstavljaju 2D elektrostatičke i površinske osobine, a atributi 4827–5408 predstavljaju 3D osobine zasnovane na rastojanjima. Nedostajuće vrednosti su u izvornom fajlu označene znakom ?.

Najvažnija odlika skupa je izrazita nebalansiranost klasa: od 16772 sloga samo je 143 aktivnih (oko 0.85%), dok su preostali neaktivni. Ova nebalansiranost suštinski određuje izbor metrika i način obrade, jer model koji bi sve slogove proglasio neaktivnim imao bi tačnost oko 99%, a bio bi potpuno beskoristan.


Nedostajuće vrednosti javljaju se u 180 slogova (Slika 1). Detaljnijom analizom utvrđeno je da su 57 slogova potpuno prazni (nedostaju sve vrednosti), a preostala 123 sloga nemaju ceo 2D blok atributa (svih 4826 vrednosti). Svi slogovi sa nedostajućim vrednostima pripadaju klasi **inactive**, što znači da se mogu izbaciti bez gubitka ijednog aktivnog sloga.

Atributi su realne vrednosti različitih opsega i razmera, što se vidi i



Slika 1: Slogovi sa nedostajućim vrednostima: 57 potpuno praznih i 123 bez 2D bloka.

na raspodeli njihovih srednjih vrednosti i standardnih devijacija (Slika 2). Zbog toga je standardizacija atributa pre modelovanja neophodna.



Slika 2: Raspodela srednjih vrednosti i standardnih devijacija atributa.

3 Preprocesiranje

Preprocesiranje je sprovedeno u nekoliko koraka:

- **Uklanjanje nedostajućih vrednosti.** Izbačeno je svih 180 slogova sa nedostajućim vrednostima. Pošto svi pripadaju klasi *inactive*, zadržana su sva 143 aktivna sloga, a skup je sveden na 16592 sloga.

- **Kodiranje ciljnog atributa.** Klasa je prevedena u brojeve: `active` postaje 1 (klasa od interesa), a `inactive` postaje 0.
- **Podela na trening i test skup.** Korišćena je stratifikovana podela u odnosu 80:20, čime se isti odnos klasa zadržava u oba dela. Trening skup ima 13273 sloga (114 aktivnih), a test skup 3319 slogova (29 aktivnih).
- **Standardizacija.** Atributi su standardizovani (oduzeta srednja vrednost, podeljeno standardnom devijacijom). Skaler je naučen isključivo na trening skupu, pa primenjen na oba dela, kako se informacije iz testa ne bi prenele u trening.

Preprocesirani podaci i naučeni skaler sačuvani su na disk, da bi se kasniji koraci mogli ponavljati bez ponovnog učitavanja izvornog skupa.

4 Redukcija atributa


Pošto skup ima 5408 atributa, što usporava modele i otežava analizu, napravljena su tri skupa atributa nad kojima se grade i porede modeli:

- **Svi atributi** – svih 5408 atributa, bez redukcije.
- **PCA 100** – analiza glavnih komponentata (PCA) zadržava prvih 100 komponenti duž kojih podaci najviše variraju. Tih 100 komponenti objašnjava oko 65% ukupne varijanse.
- **Selekcija 300** – biraju se 300 originalnih atributa koji su najjače povezani sa klasom, pomoću ANOVA F-testa.

I PCA i selekcija atributa naučeni su samo na trening skupu, a zatim primenjeni na test skup, na isti način kao i standardizacija.

5 Vizuelizacija podataka

Slika 3 prikazuje raspodelu klasa, na kojoj se jasno vidi nebalansiranost. Da bi se 5408-dimenzioni prostor mogao prikazati, atributi su projektovani u 2D i 3D pomoću PCA (linearna projekcija) i t-SNE (nelinearna projekcija na uzorku). Slike 4 i 5 prikazuju PCA projekcije, a Slika 6 t-SNE projekciju. Ni na jednoj se aktivni mutanti ne izdvajaju u jasno odvojen klaster, što ukazuje na težinu problema.



Slika 3: Raspodela klasa: 143 aktivna naspram 16629 neaktivnih slogova.

6 Metode klasifikacije

Korišćeno je šest algoritama klasifikacije: logistička regresija, stablo odlučivanja, Random Forest, linearni SVM (treniran SGD algoritmom radi brzine na velikom broju atributa), KNN i naivni Bayes. Svaki algoritam je treniran nad sva tri skupa atributa, što daje ukupno 18 modela.

Zbog izrazite nebalansiranosti, kod modela koji to podržavaju korišćena je opcija `class_weight = balanced`, koja retkoj klasi `active` daje veću težinu. KNN i naivni Bayes nemaju tu opciju. Umesto tehnike preuzorkovanja (na primer SMOTE) izabran je ovaj pristup, jer u ovako visokodimenzionom prostoru sa svega 114 aktivnih slogova u treningu sintetisanje veštačkih primera nije pouzdano.


Kvalitet modela meren je sa više metrika: tačnost, balansirana tačnost, preciznost, odziv (recall), F1-mera, ROC-AUC i PR-AUC. Naglasak je na odzivu i F1-meri za klasu `active`, kao i na PR-AUC, jer je tačnost na ovako nebalansiranom skupu obmanjujuća.

Algoritam 1 sažima ceo tok eksperimenta.

7 Eksperimentalni rezultati

7.1 Rezultati na jednoj podeli

Tabela 1 prikazuje rezultate svih 18 modela na test skupu, dobijene jednom stratifikovanim podelom 80:20. Prikazani su odziv, F1-mera, ROC-AUC i PR-AUC za klasu `active`.



Slika 4: PCA projekcija u 2D, obojena po klasi.


7.2 Unakrsna validacija

Pošto test skup sadrži svega 29 aktivnih slogova, metrike na jednoj podeli su osetljive na slučajnost. Zato je sprovedena i 5-struka stratifikovana unakrsna validacija. Redukcija atributa je u svakom foldu naučena samo na trening delu tog folda, čime se izbegava curenje informacija. Tabela 2 prikazuje prosek i standardnu devijaciju F1-mere i PR-AUC.

Slika 7 grafički poredi modele po više metrika na jednoj podeli, a slika 8 prikazuje rezultate unakrsne validacije sa standardnom devijacijom kao greškom.

7.3 Podešavanje hiperparametara

Za najbolji model (Random Forest) sprovedeno je podešavanje hiperparametara metodom `GridSearchCV`, na svim atributima, sa ocenjivanjem po PR-AUC i 3-strukom unakrsnom validacijom. Najbolja kombinacija je: broj stabala 300, bez ograničenja dubine, minimalan broj uzoraka u listu 1, sa PR-AUC u validaciji 0.561. Na test skupu podešeni model daje F1-meru 0.462 i PR-AUC 0.340. U poređenju sa podrazumevanim Random Forest-om (F1 0.440, PR-AUC 0.343), poboljšanje je malo, što pokazuje da je podrazumevani model već dobro podešen za ovaj problem.



Slika 5: PCA projekcija u 3D, obojena po klasi.


7.4 Finalni model

Kao finalni model izabran je podešeni Random Forest na svim atributima. Slika 9 prikazuje njegovu matricu konfuzije na test skupu, odnosno koliko aktivnih i neaktivnih slogova je tačno, a koliko pogrešno klasifikovano.

8 Diskusija

Rezultati pokazuju nekoliko jasnih zaključaka. Random Forest je najbolji i najstabilniji model: u unakrsnoj validaciji na svim atributima ima najvišu F1-meru (0.523) i najviši PR-AUC (0.551). Logistička regresija ima najviši ROC-AUC (0.958), što znači da odlično rangira aktivne slogove iznad neaktivnih, ali ima nisku preciznost.

Modeli se grubo dele na dva profila. Logistička regresija i SVM sa balansiranim težinama hvataju veliki deo aktivnih slogova (visok odziv), ali uz mnogo lažnih uzbuna (niska preciznost), pa im je F1-mera niska. Random Forest i KNN imaju bolju ravnotežu i bolji PR-AUC. Naivni Bayes je najslabiji na svim atributima (F1 0.050), jer njegova pretpostavka o nezavisnosti atributa pada na 5408 koreliranih atributa; zanimljivo je da je na PCA bolji, jer su komponente PCA međusobno nekorelisane.



Slika 6: t-SNE projekcija u 2D (svi aktivni i uzorak neaktivnih slogova).

Što se tiče redukcije atributa, modeli na svim atributima su generalno najbolji, naročito za logističku regresiju, SVM i KNN. Ipak, Random Forest na redukovanim skupovima (PCA 100 i selekcija 300) zadržava skoro isti PR-AUC (oko 0.49) kao na svih 5408 atributa (0.55), uz mnogo manji broj dimenzija, što je koristan kompromis.

Treba istaći da su apsolutne vrednosti F1-mere i preciznosti niske. To nije posledica loših modela, već prirode problema: u celom skupu ima svega 143 aktivna sloga, pa je istovremeno postizanje visoke preciznosti i visokog odziva veoma teško. Visoke vrednosti ROC-AUC (0.92–0.96) potvrđuju da modeli zapravo dobro razdvajaju klase. Jedno ograničenje rada je i to što su finalne ocene zasnovane na jednoj podeli i jednoj unakrsnoj validaciji.

9 Zaključak

U radu je skup „p53 Mutants” obrađen metodom klasifikacije. Sprovedeno je preprocesiranje (uklanjanje nedostajućih slogova, kodiranje klase, stratifikovana podela i standardizacija), napravljena su tri skupa atributa (svi, PCA i selekcija) i istreniran je šest algoritama na svakom, ukupno 18 modela. Modeli su upoređeni na jednoj podeli i unakrsnom validacijom, a za najbolji je dodatno sprovedeno podešavanje hiperparametara.

Random Forest se pokazao kao najbolji i najpouzdaniji model, naročito na svim atributima. Redukcija atributa zadržava najveći deo kvaliteta

Algorithm 1 Tok eksperimenta

```
1: učitaj i očisti podatke (izbaci slogove sa nedostajućim vrednostima)
2: kodiraj klasu i podeli na trening i test (stratifikovano 80:20)
3: standardizuj atribute (skaler naučen samo na trening skupu)
4: for svaki skup atributa (svi, PCA 100, selekcija 300) do
5:     for svaki algoritam (od šest) do
6:         istreniraj model na trening skupu
7:         izračunaj metrike na test skupu
8:     end for
9: end for
10: proveriti stabilnost rezultata unakrsnom validacijom
11: izaberi najbolji model i podesi mu hiperparametre
```

uz znatno manje dimenzija. Niske apsolutne vrednosti F1-mere posledica su izrazite nebalansiranosti i težine samog problema, dok visoke vrednosti ROC-AUC pokazuju da modeli dobro razdvajaju aktivne od neaktivnih mutanata. Mogući pravci daljeg rada uključuju isprobavanje tehnika preuzorkovanja, podešavanje praga odlučivanja i jaču selekciju atributa.

Literatura


- [1] UCI Machine Learning Repository, „p53 Mutants Data Set,” <https://archive.ics.uci.edu/dataset/188/p53+mutants>.
- [2] S. A. Danziger i dr., „Predicting Positive p53 Cancer Rescue Regions Using Most Informative Positive (MIP) Active Learning,” *PLOS Computational Biology*, 5(9), 2009.
- [3] F. Pedregosa i dr., „Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, 12, str. 2825–2830, 2011.

Tabela 1: Rezultati na jednoj podeli (test skup).


skup	model	odziv	F1	ROC-AUC	PR-AUC
svi atributi	Logistička regresija	0.586	0.447	0.958	0.323
	Stablo odlučivanja	0.345	0.351	0.670	0.129
	Random Forest	0.379	0.440	0.930	0.343
	Linearni SVM	0.517	0.385	0.918	0.234
	KNN	0.172	0.213	0.786	0.204
	Naivni Bayes	0.759	0.047	0.744	0.020
PCA 100	Logistička regresija	0.724	0.145	0.895	0.221
	Stablo odlučivanja	0.138	0.151	0.566	0.031
	Random Forest	0.276	0.348	0.922	0.324
	Linearni SVM	0.724	0.148	0.899	0.224
	KNN	0.276	0.320	0.802	0.220
	Naivni Bayes	0.552	0.211	0.845	0.119
selekcija 300	Logistička regresija	0.690	0.175	0.929	0.215
	Stablo odlučivanja	0.310	0.273	0.651	0.082
	Random Forest	0.414	0.387	0.890	0.324
	Linearni SVM	0.690	0.172	0.919	0.169
	KNN	0.379	0.449	0.786	0.317
	Naivni Bayes	0.586	0.114	0.853	0.052

Tabela 2: Unakrsna validacija (5 foldova): prosek $\pm$ standardna devijacija.


skup	model	F1	PR-AUC
svi atributi	Logistička regresija	0.494 ± 0.069	0.422 ± 0.088
	Stablo odlučivanja	0.314 ± 0.025	0.106 ± 0.015
	Random Forest	0.523 ± 0.096	0.551 ± 0.142
	Linearni SVM	0.364 ± 0.099	0.433 ± 0.092
	KNN	0.446 ± 0.110	0.351 ± 0.121
	Naivni Bayes	0.050 ± 0.004	0.023 ± 0.003
PCA 100	Logistička regresija	0.189 ± 0.027	0.367 ± 0.057
	Stablo odlučivanja	0.340 ± 0.090	0.131 ± 0.066
	Random Forest	0.461 ± 0.101	0.492 ± 0.081
	Linearni SVM	0.145 ± 0.022	0.315 ± 0.095
	KNN	0.402 ± 0.111	0.364 ± 0.099
	Naivni Bayes	0.174 ± 0.098	0.205 ± 0.062
selekcija 300	Logistička regresija	0.206 ± 0.023	0.319 ± 0.102
	Stablo odlučivanja	0.279 ± 0.061	0.088 ± 0.032
	Random Forest	0.498 ± 0.098	0.493 ± 0.107
	Linearni SVM	0.153 ± 0.051	0.406 ± 0.114
	KNN	0.397 ± 0.062	0.355 ± 0.096
	Naivni Bayes	0.147 ± 0.034	0.072 ± 0.026



Slika 7: Poređenje modela po metrikama (jedna podela).



Slika 8: Poređenje modela u unakrsnoj validaciji (prosek i standardna devijacija).



Slika 9: Matrica konfuzije finalnog Random Forest modela (test skup).